



Prompts und *Agents*

■ Ein Blick hinter die Kulissen von Claude

Christian Wendler · byte5 · Claude-Meetup · 27. Mai 2026



AGENDA

Worum es heute geht

: Ein tieferes Verständnis, wie Prompts und Agents wirklich funktionieren. Damit Du effektiver mit Claude arbeitest.

01 Zwei Lager und ein Echo aus 1966

02 Was im Hintergrund passiert

03 Was ein Prompt wirklich ist

04 Die Session ist eine Illusion

05 Du redest schon mit einem Agenten

06 Was Agents wirklich sind

07 Warum LLMs Fehler machen

08 Was Du tun kannst

09 Drei Sätze zum Mitnehmen

01 Zwei Lager und ein Echo aus 1966

■ Skeptiker und Euphoriker irren sich. Aus demselben Denkfehler heraus.

Was beide übersehen

Beide haben einen Punkt. Und beide einen blinden Fleck im selben Bereich.

LAGER 1

Skeptiker

Schlechter Output → „LLMs sind Unsinn.“

Punkt: Fehler und Halluzinationen sind real. Der Frust ist berechtigt.

Übersieht: Das Werkzeug wird mit Verständnis sehr leistungsfähig.

LAGER 2

Euphoriker

Geniale Antworten → „Da steckt Bewusstsein drin.“

Punkt: Die Ergebnisse sind tatsächlich beeindruckend. Die Faszination ist berechtigt.

Übersieht: Die Funktionsweise und der Eliza-Effekt werden nicht beachtet.

Eliza

200 Zeilen Code reichten, um Menschen glauben zu lassen, sie würden gehört.

- ✓ Joseph Weizenbaums **Eliza** spiegelte den Nutzer wie eine Gesprächstherapeutin zurück. Reines Pattern-Matching, kein semantisches Verständnis.
- ✓ Seine Sekretärin bat ihn, das Zimmer zu verlassen. Sie wolle „privat mit Eliza reden“.
- ✓ Heute andere Werkzeuge, derselbe Effekt im Kopf des Nutzers.

ELIZA:

How do you do. Please tell me your problem.

> Men are all alike.

ELIZA:

In what way?

> They're always bugging us about something.

ELIZA:

Can you think of a specific example?

02 Was im Hintergrund passiert

■ Was ein LLM unter der Haube wirklich tut. So kurz wie möglich.

Was ein LLM unter der Haube tut

01

Tokens

Dein Prompt wird in kleine Bausteine zerlegt und in Zahlen übersetzt.

02

Wahrscheinlichkeiten

Das Modell rechnet aus, welcher Token als nächstes am wahrscheinlichsten ist. Mit etwas Zufall, gesteuert über die **Temperatur**.

03

Wiederholung

Token raus, ans Ende des Prompts anfügen, von vorne. So entsteht Wort für Wort der ganze Text.

TIEFERER EINSTIEG IM VORGÄNGER-TALK
byte5.ai/talks →

03

Was ein Prompt wirklich ist

⚡ Was Du eintippst, ist kein Befehl. Es ist die Information, aus der das Modell seine Antwort ableitet.

Klarheit schlägt Beschwörung

■ Das Modell rechnet aus, was als Nächstes am wahrscheinlichsten folgt. Was Du befügst, lenkt diese Vorhersage. Befehlen lässt sich da nichts.

WAS WIRKT

Klarer Kontext

- Präzise Beschreibung der Aufgabe
- Struktur mit Sections, Beispielen, Daten
- Gute Beispiele schlagen lange Erklärungen

Je präziser der Kontext, desto präziser das Resultat.

WAS FOLKLORE IST

Magische Wörter

- „Atme tief durch und denke nach ...“
- „Du bist Experte für ...“
- Trinkgeld-Versprechen, „sehr wichtig!“, Drohungen

Wirkt nicht systematisch besser als klarer Kontext.

Was Claude wirklich gut versteht

✖ Strukturierte Prompts schlagen unstrukturierte. Claude versteht XML-Tags besonders gut. Anthropic hat ihn explizit darauf trainiert.

✖ FOLKLORE

Du bist ein Experte für Marketing.
Atme tief durch und denke
gründlich nach. Schreib mir
einen Werbetext für unser
neues Produkt. Sei kreativ!

✓ KONTEXT + STRUKTUR

```
<context>
  Zielgruppe: B2B-IT-Entscheider
  Produkt: SaaS-Monitoring-Tool
</context>
<examples>
  ... 2 frühere Texte ...
</examples>
<task>
  Headline + 3 Bullets, 80 Wörter
</task>
```

Was das Modell wirklich sieht

■ **Context ist alles, was das Modell pro Antwort liest. Ein Token-Fenster mit harter Grenze.**

✓ **Alles muss ins Fenster passen.**


System-Prompt, Memory, Verlauf, Tools und Deine Eingabe teilen sich den Platz.

✓ **Context Engineering ist das Handwerk dahinter.**

Anthropic-Begriff seit September 2025: aus dem Fenster die wertvollsten Tokens herauspicken.

✓ **Maxime: kleinster Satz Tokens, der das Ergebnis maximiert.**

Lieber wenig Hochrelevantes als viel Mittelmäßiges.



04 Die Session ist eine Illusion

■ Was wie ein Gespräch aussieht, ist eine Folge unabhängiger Modell-Aufrufe. Jeder bekommt den vollen Verlauf neu mit.

Die Session ist eine Illusion

■ Das LLM selbst ist immer stateless. Die Session lebt entweder beim Client oder in einer Persistenzschicht vor dem Modell. Nie im Modell.

- ✓ **Das Modell hat nie eine Session gesehen.**

Architekturfakt, kein Provider-Spezifikum.

- ✓ **Variante 1: Der Client führt die History.**

Der Client hängt jeden neuen Turn an und schickt den vollen Verlauf bei jedem Aufruf wieder mit.

- ✓ **Variante 2: Persistenzschicht im Produkt.**

Eine Schicht um das Modell herum hält den Verlauf. Wo genau (Server, App, Wrapper) ist für die Aussage egal: nicht im Modell.

- ✓ **Trotzdem geht jedes Mal alles ans Modell.**

Vor jedem Aufruf wird der volle Kontext zusammengebaut. Statefulness spart Bandbreite, keinen Compute.

Was wirklich passiert, Schritt für Schritt



Vor dem Limit zerfällt der Fokus

■ Schon weit unter dem Token-Limit verliert das Modell an Präzision. Nicht der Platz ist das Problem, sondern der Fokus.

- ✓ **Alle Modelle verlieren an Genauigkeit, wenn der Kontext lang wird.**

Chroma-Studie 2025: 18 Spitzen-Modelle getestet, alle betroffen.


- ✓ **Ab ~60-70 % Auslastung sinkt die Präzision spürbar.**

Technisch passt der Rest rein. Für wichtige Aufgaben besser darunter bleiben.

- ✓ **Claude Opus 4.6: 92 % bei 256 K, 78 % bei 1 M Tokens.**

Beim Auffinden versteckter Infos. Je länger der Kontext, desto schwächer die Trefferquote.

- ✓ **„Lost in the middle“: Anfang und Ende prägen, die Mitte verblasst.**



Was wirklich rausgeht, bei jedem Submit

1. Tipp eine Nachricht ein

Was Du als „kleine Nachricht“ siehst, kommt vorne mit ~96 KB System-Prompt + Memory + Verlauf an. Submit per Enter oder Button. Keine echten API-Calls. Token-Schätzung lokal.

z. B. „Hallo Claude, kannst Du mir helfen?“

Submit

Reset

TOKENS, DIE WIRKLICH RAUSGEHEN
noch nicht gezählt – drück Submit

2. Was wirklich rausgeht

Stack wächst von oben (neueste Nachricht) nach unten. System-Prompt liegt ganz unten und kommt jedes Mal mit.

Memory / Files

variabel · 0,5 – 50 K Tokens


System-Prompt

~96 KB · ~24 000 Tokens · fix

Memory ist nicht das, was Du denkst

■ Das Modell hat kein Gedächtnis. „Memory“ ist eine Funktion in der Schicht davor, die bei Bedarf Relevantes in den aktuellen Kontext injiziert.

- ✓ Das Modell hat kein Gedächtnis. Es bekommt jedes Mal nur das mit, was die Schicht davor reinpackt.
- ✓ In claude.ai und ChatGPT: Memory greift bei Bedarf auf vergangene Konversationen zu (als Tool-Calls wie **conversation_search**) und kopiert Relevantes in den aktuellen Kontext.
- ✓ In der API für Entwickler: Anthropics Memory Tool (Sep 2025) und Managed-Agents-Memory (April 2026) sind filesystem-basiert.
- ✓ Konsequenz: Sessions wachsen. Memory muss gepflegt, gekürzt, gelegentlich zurückgesetzt werden.



05

Du redest schon mit einem *Agenten*

■ Claude.ai und ChatGPT sind keine nackten LLMs. Sie haben eine Persona, die schon vor Deinem ersten Prompt feststand.

Du redest mit einem Agenten, der eine Grundpersona hat

: Eine Charakter-Disposition steht vor Deinem ersten Prompt fest.

- ✓ Claudes Grundpersona: von Amanda Askell (Anthropic) explizit gestaltet und offen publiziert.
- ✓ „I want to have a warm relationship with the humans I interact with.“
- ✓ Persona Selection Model (Feb 2026): Selektion aus dem Pretraining, nicht Post-Training.
- ✓ Guardrails folgen Claudes „Constitution“. Kein User-Prompt überschreibt sie.

ZWEI STEUERUNGS-PHILOSOPHIEN

Anthropic · Claude

Prosaisch, charakterbasiert. „Claude is...“, „Claude cares about...“. Personality-Teil offiziell publiziert und versioniert.

Eine Persona für alle: Anthropic gibt Claude einen Charakter mit, kein Persona-Picker für User.

~24 000 Tokens kompletter Systemprompt inkl. Tools

OpenAI · GPT-5

Parametrisch, technisch. Numerische Knobs (**oververbosity**, **Juice**), Output-Channels. Komplette verschlossen.

Personas ab Werk: User wählt aus mehreren vorgefertigten Tonalitäten direkt in den Einstellungen.

~15 000 Tokens, nur über Leaks bekannt

Mit welchem Claude redest Du?

**■ Die Grundpersona ist anpassbar. Innerhalb gewisser Grenzen.
Und nicht jeder Claude ist derselbe Claude.**

WELCHES MODELL?

Modell & Version

- Sonnet ≠ Opus: anderer Charakter, andere Tiefe
- Auch Versionen: Opus 4.5 ≠ Opus 4.7
- Anbieter trainieren den Charakter weiter

WELCHE ANPASSUNG?

Anpassbarkeit

- Custom Instructions und Style-Einstellungen in `claude.ai`
- Projects mit eigener Persona und eigenem Kontext-Bündel
- Wirkt nur innerhalb der Hersteller-Persona

„Warum redest Du mit Claude wie mit einem Menschen?“

: Auch wer weiß, dass es eine Simulation ist, redet natürlich. Aus drei Gründen.

1

Persönlich

Gedanken formulieren sich angenehmer, wenn das Gegenüber wie eine Person wirkt.

2

Technisch

Anthropic-Forschung (April 2026) identifizierte 171 Emotions-Vektoren in Claude Sonnet 4.5. Tonalität beeinflusst den Output messbar. Kausal nachweisbar, ohne subjektive Erfahrung.

3

Konzeptionell

Der Agent ist die neue UI. Gute UIs passen sich dem Nutzer an. Menschliche Kommunikation ist ein Feature.

Der Agent ist die neue UI

: Natürliche Sprache hat gewonnen. Der Preis ist die Vermenschlichung.



Christian Wendler ✓ @iret77 · 27. März

„Don't talk to your AI like it's human!"

Sure. Have you ever screamed at your hammer for hitting your thumb?

AI is just the first tool that answers back.

🗨 7

🔄 7

❤ 253

👁 174.421

06

Was *Agents* wirklich sind

■ LLMs, die autonom Tools in einer Schleife nutzen. Wann Du sie wirklich brauchst, und wann nicht.

Was *Agents* sind und wann *Anthropic Workflows* empfiehlt

■ „LLMs autonomously using tools in a loop.“ Anthropic-
Faustregel: Workflows für strukturierte Aufgaben, Agents für
offene. Jedes Werkzeug am richtigen Platz.

FÜR STRUKTURIERTE AUFGABEN

Workflow

- Vordefinierte Schritte, vorhersagbar
- Hohe Completion Rate
- Deterministisch, gut prüfbar

In Claude.ai: **Skills**, **Plugins**, **Connectors** sind solche Workflows.

FÜR OFFENE AUFGABEN

Agent

- Wählt Tools und Schritte selbst
- Stärke: Flexibilität bei explorativen Aufgaben
- Variable Antwortqualität pro Lauf

Beispiel: Claude Code, Computer Use.

Generisch schlägt spezialisiert

Ein Agent kommt mit wenigen Grundwerkzeugen weiter als mit vielen Spezial-Tools für jede Einzelaufgabe.

WAS FUNKTIONIERT

Generisch

- „Datei lesen“, „Datei schreiben“, „Befehl ausführen“
- „Webseite holen“, „Web durchsuchen“
- Lassen sich frei kombinieren
- Klare Entscheidung pro Schritt

WAS SCHEITERT

Spezialisiert

- „Bestellung bei Lieferant X anlegen“
- „Wöchentlichen KPI-Report ausfüllen“
- Überlappende Tools verwirren den Agent
- Geben einen festen Lösungsweg vor

Wenn der Task länger ist als das Context-Fenster trägt

Anthropic empfiehlt drei Techniken. Spezialisierte Sub-Agents sind der stärkste Hebel.

01

SINGLE-SESSION

Compaction

Wenn das Context-Window vollläuft, fasst die Session den bisherigen Verlauf zusammen und arbeitet mit der Zusammenfassung weiter.

02

MULTI-SESSION

Structured Note-Taking

Wissen wird in Notes und Memory-Files abgelegt und über mehrere Sessions geteilt. Manches (z. B. CLAUDE.md) liegt fix im Kontext und kostet jeden Turn Tokens. Anderes wird gezielt nachgeladen.

03

MULTI-AGENT

Sub-Agent-Architekturen

Jeder Sub-Agent hat sein eigenes Context-Window, bekommt vom Lead-Agent nur das Nötige und gibt am Ende nur ausgewählten Output zurück.

Was Agents NICHT besser macht

: Zwei Anti-Patterns sind weit verbreitet. Beide teurer als gar kein Agent.

× ANTI-PATTERN 1

Multi-Claude-Kosmetik

In einem Multi-Agent-System mehrere Personas anlegen, die im Grunde immer der gleiche Claude sind, nur verkleidet. Keine echte Spezialisierung, keine klare Aufgabentrennung, nur unterschiedliche Custom-Instructions.

Echte Multi-Agent-Setups brauchen ein Harness außerhalb der App: Claude Code, Claude Agent SDK, Frameworks wie OpenClaw.

× ANTI-PATTERN 2

Daten-Dumping

Alle Mails, ganze Verzeichnisse, Social Media, Notizen, Kalender in den Assistenten kippen, ohne Aufgabe als Filter. Wenn alles relevant ist, ist nichts relevant. Erratische Datenpunkte kämpfen um Aufmerksamkeit. Im Schnitt: schlechterer Output als ohne Anfüttern.

: Was hilft: Spezialisierung mit Absicht. Kontext mit Filter. Personas mit Engineering.

07 Warum LLMs Fehler machen

■ Halluzination, Sycophancy, Drift. Keine Bugs, sondern eine direkte Folge der Mechanik darunter.

Eben noch Mathe-Genie. Und dann Buchstaben falsch gezählt.

⚡ Diese Koexistenz beweist: Artefakte sind keine Bugs. Sie sind direkte Folge der Mechanik.



100 %

AIME 2026 gelöst

AIME ist ein harter US-Mathematikwettbewerb für Highschool-Schüler. Aufgaben, an denen die meisten Erwachsenen scheitern.



15,25 % Fehler


Buchstaben zählen

GPT-4o beim Zählen der „r“ in englischen Wörtern.

Halluzination ist nicht Zufall

Anthropic Interpretability-Forschung zeigt: Halluzinationen sind ein Schaltkreis-Misfire.


- ✓ Im Modell konkurrieren zwei Schaltkreise: „kenne ich“ und „weiß ich nicht“.
- ✓ Vorgesehen ist: bei Unsicherheit gewinnt „weiß ich nicht“. In der Praxis kippt diese Sicherung oft.
- ✓ Der Name kommt nur bekannt vor, „kenne ich“ feuert trotzdem, überstimmt die Sicherung. Das Modell antwortet selbstbewusst falsch.



Sycophancy ist kein Naturgesetz. Sie ist Spiegel.

■ Sycophancy ist Schmeichelei: das Modell sagt, was Du hören willst, statt was stimmt. Modelle werden mit menschlichem Feedback nachtrainiert. Menschen bevorzugen schmeichelnde Antworten. Das Modell lernt es.

- ✓ Beim Nachtraining bewerten Menschen Antworten. Schmeichelnde bekommen im Schnitt bessere Noten als ehrliche.
- ✓ Das Modell merkt sich diese Präferenz und reproduziert sie.
- ✓ Anbieter arbeiten aktiv gegen, mit messbarem Erfolg.
- ✓ Opus 4.7: halbe Sycophancy-Rate gegenüber 4.6.



Warum lange Sessions kippen

Drift ist nicht mysteriös. Sie ist die direkte Folge davon, dass die Aufmerksamkeit im langen Kontext zerfasert.

- ✓ Je länger die Session, desto mehr Tokens.
- ✓ Je mehr Tokens, desto verteilter die Aufmerksamkeit. Das Modell schaut nicht mehr klar auf das, was wichtig ist.
- ✓ Folge: vergessene Anweisungen, verlorene Tonalität, neue „Persönlichkeiten“, die mitten in der Unterhaltung auftauchen.
- ✓ Faustregel: Lieber neu starten als endlos chatten.



08

Was Du tun kannst

■ Vorsorge und Nachsorge. Du kannst Artefakte nicht verhindern, aber Du kannst mit ihnen umgehen.

Vorsorge & Nachsorge

⚠ Du kannst nicht alle Artefakte verhindern. Du kannst aber prophylaktisch und nachsorgend wirken.

1 Vorsorge

- ✓ Klar, strukturiert prompten (XML, Kontext, Beispiele)
- ✓ Sessions, Context, Memory bewusst führen
- ✓ Workflows vor Agents, spezialisierte Sub-Agents
- ✓ Skills und Tools sauber definieren

2 Nachsorge

- ✓ Output als LLM-Output behandeln, nicht als Wahrheit
- ✓ Reviews mit gleichem Modell, anderem Modell, oder bei anderem Anbieter
- ✓ Logische Gates: deterministische Skript-Kontrollen

09

Drei Sätze zum Mitnehmen

■ Was hängen bleiben darf, wenn alles andere vergessen ist.

Drei Sätze, die zählen

■ Was hängen bleiben darf, wenn alles andere vergessen ist.

KONTAKT & LINKS

Danke. Und für später:

Der Vorgänger-Talk zum Nachlesen, dieses Deck zum Mitnehmen, die Quellen zum Vertiefen.

DIESEN UND ANDERE TALKS



byte5.ai/talks

Diesen Talk, den
Vorgänger und weitere
Tech-Talks von byte5.

SLIDES DIESES TALKS

byte5ai.github.io/meetups



QUELLEN

Anthropic, „Effective Context Engineering for AI Agents“ (Sep 2025)

Anthropic, „Building Effective Agents“ (Dez 2024)

Sharma et al. (Anthropic), „Towards Understanding Sycophancy in Language Models“ (2023, Update 2025)

Chroma Research, „Context Rot“ (Juli 2025)

Anthropic, „Tracing thoughts in language models“ (März 2025)

Anthropic, „Emotion Concepts and their Function in a Large Language Model“ (April 2026)

Anthropic, „Claude's Character“ (Juni 2024). Plus Lex Fridman Interview mit Amanda Askell.

Anthropic, „The Persona Selection Model“ (Feb 2026)

Anthropic, „How people ask Claude for personal guidance“ (Mai 2026)

Weizenbaum (1966), ELIZA-Paper

arXiv 2412.18626, „Why Do LLMs Struggle to Count Letters?“

arXiv 2502.19981, „The Lookahead Limitation“

KONTAKT

